

Projet Final de M8
Étude de Teen Quotes

Antoine AUGUSTI,

Juin 2013

Table des matières

1	Introduction	2
1.1	Teen Quotes, qu'est-ce que c'est ?	2
1.2	Et moi, je peux avoir accès à Teen Quotes ?	2
1.3	Des données oui, mais des données à jour	3
1.3.1	Comment ça fonctionne ?	3
2	Halte ! Qui va là ?	4
2.1	Où habites-tu petit visiteur ?	4
2.2	Plutôt smartphones ou ordinateurs ?	6
2.3	On ne passe pas assez de temps ensemble	8
2.4	C'est un garçon ou une fille ?	8
3	Des citations, par milliers	10
3.1	Les statuts des quotes (<i>Statu quo</i>)	10
3.2	Vous allez vite en besogne	12
3.3	Petits floodeurs ou gros floodeurs ?	13
4	Les utilisateurs sont nos amis	15
4.1	Plus on est de fous, plus on rit	15

1 Introduction

1.1 Teen Quotes, qu'est-ce que c'est ?

Teen Quotes est une plateforme regroupant des citations décrivant le quotidien des adolescents. L'adolescence est une période difficile à gérer dans la vie et les adolescents ont souvent besoin d'échanger autour de sujets qui les préoccupent : leurs amis, l'amour, les études, leurs déceptions, leurs expériences. Teen Quotes répond à ce besoin en proposant à toute personne possédant un compte de pouvoir partager son impression en écrivant une courte citation. Cette citation sera ensuite acceptée (modifiée légèrement ou non) pour publication ou rejetée. Actuellement, cinq nouvelles citations sont publiées tous les jours à 0h (heure française) sur Teen Quotes.

L'interface de Teen Quotes est proposée par défaut en anglais. L'interface est également disponible en français pour ceux qui le désirent et une version en français par défaut existe (elle se nomme Kotado). Toutefois, la version française de Teen Quotes ayant moins de succès que la version originale, j'ai choisi d'orienter mon projet de M8 vers cette version anglaise.

Teen Quotes a été lancé en mai 2011, après quelques mois de développement que j'ai mené seul. Aujourd'hui Teen Quotes possède une version web pour les ordinateurs, une version optimisée pour les smartphones (depuis navigateur) ainsi qu'une application iPhone / iTouch que l'on peut télécharger depuis l'App Store d'Apple. **Plus de 1,5 million de personnes ont visité Teen Quotes**, depuis l'une des versions que nous proposons.

Je me suis également associé depuis deux ans à une jeune femme philippine (parlant anglais) qui tient le compte Twitter de Teen Quotes (*@ohteenquotes*) comptant actuellement **plus de 2 millions de followers**. Nous essayons ensemble d'avoir une convergence vers tous les supports où Teen Quotes est présent (Twitter, Facebook, site web, site mobile, application iPhone / iTouch) pour agrandir notre masse d'utilisateurs.

1.2 Et moi, je peux avoir accès à Teen Quotes ?

Bien évidemment ! Teen Quotes est ouvert à tout le monde et mon but est que le plus de monde possible rejoigne l'aventure. Teen Quotes peut être consulté grâce aux moyens suivants :

- Site web : <http://teen-quotes.com>
- Site mobile¹ : <http://m.teen-quotes.com>
- Application iPhone / iTouch² : <http://teen-quotes.com/apps>

1. Lien à visiter depuis un smartphone ou une tablette. La redirection vers la version mobile est automatique quand on tente de visiter le site classique depuis un smartphone ou une tablette.

2. Lien à visiter depuis un iPhone ou un iTouch pour lancer le téléchargement de l'application !

1.3 Des données oui, mais des données à jour

Teen Quotes enregistre plus de **4 000 visites par jour**. Les bases de données de Teen Quotes enregistrent environ **30 000 requêtes par heure**. Avec un tel volume de données, difficile de se contenter d'une étude statistique figée, obsolète une semaine plus tard car les données ne sont plus du tout les mêmes. Teen Quotes est vivant, évolue en permanence : l'étude statistique de Teen Quotes doit s'adapter en conséquence.

En réponse à ce défi, j'ai décidé d'orienter mon projet de M8 vers une étude statistique évolutive, qui se renouvelle en permanence et qui a pour ambition de donner des informations correctes et précises en quasi temps réel. Pour répondre à ce besoin, quoi de mieux que de proposer une étude en ligne ? Facile à consulter : il suffit d'un navigateur web.

1.3.1 Comment ça fonctionne ?

L'idée était donc de créer une partie du site de Teen Quotes dédiée aux statistiques : affichage de graphiques et informations sur les données. Les données sont recalculées 3 fois par heure (soit **toutes les 20 minutes** si vous suivez !). La réflexion suivie pour arriver à ceci a donc été la suivante :

1. Quelles sont les données que je veux afficher ?
2. Comment est-ce que je peux récupérer ces données ? Sont-elles enregistrées dans mes bases de données ou sur un service externe (Google Analytics³, Flurry⁴) ?
3. Comment faut-il rassembler les données ? Comment donner du sens aux données brutes ? Comment les formater ?
4. Comment proposer un affichage agréable et lisible pour donner sens aux données récupérées ?
5. Comment automatiser tout ce processus pour pouvoir effectuer une mise à jour des informations toutes les 20 minutes ?

Le résultat final est visible à l'adresse <http://statistics.teen-quotes.com> et est disponible en anglais (dans un souci d'intérêt pour le public visé par Teen Quotes !) et en français. Je vous invite fortement à vous rendre à cette adresse, la suite du rapport expliquant en détail chaque graphique affiché sur cette page.

Des précisions techniques seront apportées au fur et à mesure du rapport pour vous faire une idée de comment est réalisée cette page. Programme alléchant, non ? Allez hop, en voiture, plongeons-nous dans les données !

3. Google Analytics fournit une analyse d'audience pour le site web classique et le site web mobile.

4. Flurry fournit des données sur les utilisateurs de l'application iPhone / iTouch.

2 Halte ! Qui va là ?

Quand nous avons décidé de lancer Teen Quotes, nous ne savions qu’une chose : il fallait que le site soit en anglais pour toucher le plus de monde possible à travers le globe. Partout dans le monde où il y avait un accès à Internet et où les gens parlaient anglais, nous devions pouvoir être accessibles.

Nous n’avions pas une population cible précise et pas de préférence particulière pour un ou des pays. La communication n’a jamais été orientée vers une quelconque culture ou un quelconque continent. Les statistiques obtenues sont donc une régulation naturelle des flux vers Teen Quotes.

2.1 Où habites-tu petit visiteur ?

La première chose à déterminer est la localisation géographique de connexion des visiteurs pour accéder à Teen Quotes. Ceci nous permet d’avoir en notre possession plusieurs informations importantes :

- Une connaissance de notre audience dans l’éventualité de s’orienter plus vers un pays ou un continent pour des opérations futures.
- Un besoin d’optimisation technique vers les pays de grande audience : nos serveurs sont en France mais très peu de visiteurs visitent Teen Quotes depuis la France.

Les données de localisation des visites sont données par Google Analytics pour le site web et le site pour mobiles. Les données de localisation pour l’application iPhone / iTouch sont fournies par Flurry. Flurry se contente de donner des informations au niveau des continents alors que Google Analytics est capable de déterminer la localisation au niveau des villes de taille moyenne (Rouen par exemple). Dans un souci de respect de la vie privée des utilisateurs, on se limite à une localisation au niveau de la ville moyenne la plus proche de son lieu de connexion.

On s’intéresse à la totalité des visites de Teen Quotes depuis la création en mai 2011 jusqu’en juin 2013 : on compte donc des personnes en double, forcément. Toutefois il est impossible de faire autrement : les visiteurs peuvent se déplacer géographiquement, changer d’adresse IP... La seule solution pour éviter les doublons serait de ne s’intéresser qu’aux visites de personnes authentifiées sur Teen Quotes, ce qui nous priverait d’une bonne partie des données.

Comme on souhaite s’intéresser aux visites par pays, on ne retient que les données de localisation du site web et du site optimisé pour mobiles en laissant de côté les données de localisation de l’application iPhone / iTouch qui a été lancée en novembre 2012.

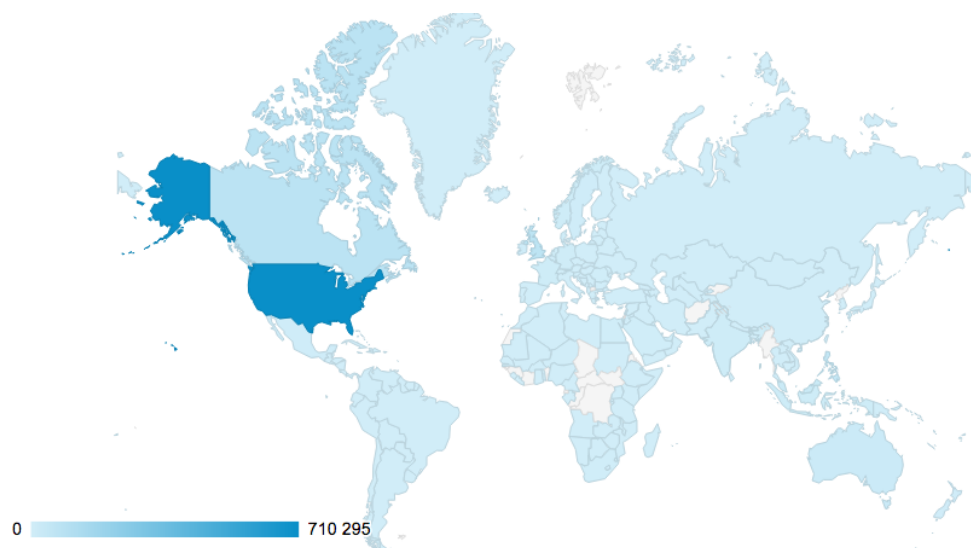


FIGURE 2.1 – Visites depuis la création de Teen Quotes représentées sur une carte mondiale.

On a appliqué un dégradé de bleu pour symboliser le nombre de visites : le bleu foncé représentant le pays avec le plus de visiteurs.

De cette carte on peut tirer l'analyse suivante :

- Quasiment tous les pays du monde sont coloriés en bleu : c'est-à-dire qu'il y a eu au moins une visite depuis 211 pays ou États¹ dans le monde. Les pays grisés sont majoritairement situés en Afrique : l'absence de visites depuis ces pays peut s'expliquer par le faible taux d'accès à Internet pour les particuliers.
- Les visites depuis les États-Unis ont l'air très majoritaires, à tel point qu'il est difficile de voir une différence pour les autres visites tant les écarts sont grands entre le pays le plus visité et les autres.

Pour mieux visualiser le poids de chaque poids, représentons les visites sur un diagramme circulaire.

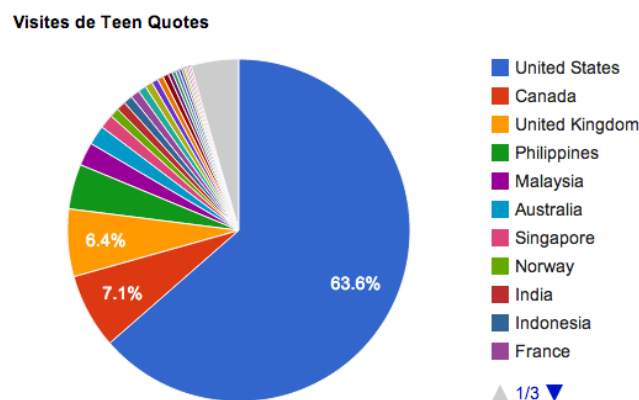


FIGURE 2.2 – Visites depuis la création de Teen Quotes représentées sur un diagramme circulaire.

1. On obtient ce chiffre en regardant la liste des pays qui ont enregistré au moins une visite, et non en les comptant sur la carte !

La tendance observée précédemment est confirmée : les États-Unis sont de loin le pays qui génère le plus de visites. Plus impressionnant encore **le top 5 des pays (États-Unis, Canada, Royaume-Uni, Philippines et Malaisie) totalise 83,5 % du total des visites**. Le reste des pays est très dispersé, contribuant chacun à environ 1 % des visites.

2.2 Plutôt smartphones ou ordinateurs ?

On a vu précédemment que l'application pour iPhone / iTouch a été lancée en novembre 2012 alors que le site web et la version mobile ont été lancés en mai 2011. Pourquoi avoir attendu autant ? Tout simplement parce qu'il s'est avéré nécessaire en observant les données au fil du temps de posséder une telle application. Retour sur cette décision !

Ici nous allons nous intéresser à l'évolution du nombre de visites par mois depuis un ordinateur, un mobile (smartphone ou tablette) et depuis l'application iPhone / iTouch quand celle-ci a été lancée.




FIGURE 2.3 – Visites mensuelles par type d'appareil.

Interprétons maintenant les résultats obtenus :

- Avant le lancement de l'application iOS on remarque qu'il y a quasiment autant de visiteurs depuis un appareil mobile que depuis un ordinateur. Cette statistique suit la montée du mobile dans les usages du web mais dans des proportions importantes : plus de 40 % des visites se font depuis un smartphone ou une tablette. C'est cette statistique qui nous a poussé à réaliser une application iPhone / iTouch.
- Après le lancement de l'application iPhone / iTouch, pratiquement 50 % des visites se font depuis l'application ! Le succès est grand. Le faible succès au mois de novembre 2012 s'explique par le lancement en fin de mois de l'application.

Maintenant, posons-nous la question : **pourquoi une application pour iOS et pas pour Android ou Windows Phone ?** Intéressons-nous aux systèmes d'exploitation mobiles qui ont navigué sur Teen Quotes.

Visites en fonction des systèmes d'exploitation des mobiles




FIGURE 2.4 – Visites en fonction des systèmes d'exploitation des mobiles.

En regardant ce diagramme, on pourrait penser que iOS est juste devant Android, sans une grande longueur d'avance. La subtilité réside dans le fait que le système d'exploitation des iPhone et iTouch est en réalité iOS : ces appareils annonçaient un nom différent il n'y a pas encore si longtemps. Il faut donc ajouter les pourcentages attribués aux systèmes d'exploitation iPhone et iTouch à iOS.

Au final, on arrive à 57,1 % des appareils mobiles sous iOS contre 31,6 % des appareils mobiles sous Android. L'explication est donc là : **pour proposer une application qui répondait le plus aux attentes de nos visiteurs il fallait créer une application pour iOS.**

2.3 On ne passe pas assez de temps ensemble

Plus un visiteur reste longtemps, plus je suis content. J'aime bien quand les visiteurs prennent le temps de lire plusieurs citations voire plusieurs pages de citations ! Le top de mon bonheur étant bien sûr la création d'un compte voire même le remplissage d'un profil. Le comble du bonheur... Mais je m'éloigne du sujet il me semble : la durée moyenne de visite d'un visiteur de Teen Quotes.

Observons donc l'évolution de la durée de visite moyenne d'un visiteur par mois depuis la création de Teen Quotes.




FIGURE 2.5 – Durée de visite moyenne d'un visiteur.

On remarque immédiatement que la durée moyenne de visite la plus basse est de plus de 4 minutes et 15 secondes. C'est une excellente moyenne pour un site web ! Bonne nouvelle : Teen Quotes arrive à retenir les visiteurs pendant plusieurs minutes. N'oublions pas que plus de 40 % des visites sont réalisées depuis un appareil mobile où la durée d'attention est généralement réduite.

On remarque que les données sont assez éparpillées : il y a un écart de quasiment 2 minutes entre la valeur minimale et la valeur maximale ! Et 2 minutes de durée de visite en moyenne de différence sur une période d'un mois, c'est beaucoup. Je n'ai pas encore trouvé d'explication à ces écarts, je tâcherai de surveiller particulièrement ceci à l'avenir.

2.4 C'est un garçon ou une fille ?

J'ai bien peur d'avoir accouché de plusieurs million de filles. Enfin pas vraiment moi, mais plutôt Teen Quotes ! La connaissance de l'audience passe aussi par le genre des visiteurs : on ne proposera pas les mêmes citations à un public majoritairement féminin que masculin. Il est donc primordial de savoir quelle est la proportion de femmes et d'hommes dans notre audience.

Les données proviennent des informations recueillies sur tous les utilisateurs de l'application iPhone / iTouch et des utilisateurs ne s'étant pas inscrits depuis l'application ayant renseigné leur sexe dans le profil de leur compte Teen Quotes. En effet, Flurry permet de connaître le sexe de l'utilisateur grâce aux informations de son compte Apple alors qu'il n'y a pas de moyen technique permettant d'identifier le sexe d'un visiteur naviguant sur le web !




FIGURE 2.6 – Proportion d'hommes et de femmes visitant Teen Quotes.

Wahou, c'est un non-match : il y a un paquet de filles. En y réfléchissant ceci peut se comprendre : les filles ont général plus besoin de se confier et de s'identifier que les garçons lors de la période de l'adolescence. Ça tombe bien, c'est exactement ce pourquoi a été créé Teen Quotes ! En plein dans le mille.

3 Des citations, par milliers

Avant de s'attarder sur le coeur de Teen Quotes (les citations), il convient de rappeler les quelques subtilités associées à celles-ci. Par commodité, on appelle les citations de Teen Quotes les **"quotes"**.

- Chaque utilisateur possédant un compte sur Teen Quotes peut soumettre 5 quotes par jour.
- Une fois une citation soumise, elle doit être acceptée avant d'être publiée. Une citation peut être acceptée telle qu'elle a été soumise ou légèrement modifiée.
- Tous les soirs à 0h (heure française), 5 nouvelles citations sont publiées.
- Il existe un système de "file d'attente" qui regroupe les citations en attente de publication : les citations ayant été approuvées les premières étant publiées en priorité.

3.1 Les statuts des quotes (*Statu quo*)

Intéressons-nous d'abord aux proportions des différents statuts de quotes.




FIGURE 3.1 – Parts des différents statuts des quotes sur Teen Quotes.

On remarque qu'une majeure partie des citations ont été refusées. Ceci s'explique par le fait que Teen Quotes est aujourd'hui mature : beaucoup de citations sont soumises et l'objectif est de garder du contenu de haute qualité tout en évitant de publier des citations ayant déjà été publiées. À l'heure actuelle, la modération est donc plus stricte. Aujourd'hui, plus de 3 800 quotes ont été publiées sur Teen Quotes.

60 quotes sont en attente de publication, ce qui signifie que le contenu est déjà prêt pour les 12 prochains jours. J'essaie de garder toujours une marge d'avance (environ 15 jours) pour le contenu qui sera publié, en cas d'imprévu personnel qui m'empêcherait de modérer des citations pendant une certaine période.

Enfin, 117 quotes sont en attente de modération. Ce nombre de quotes en attente de modération est généralement atteint en 2 ou 3 jours sans effectuer de modération.

Intéressons-nous maintenant aux différents statuts des citations, mais en fonction du temps. On fait seulement la distinction entre les citations approuvées et les citations refusées de la création de Teen Quotes jusqu'à une date donnée.




FIGURE 3.2 – Nombre de citations acceptées et refusées en fonction du temps.




FIGURE 3.3 – Pourcentage de citations acceptées et refusées en fonction du temps.

La courbe (ou l'aire) bleue est la somme des courbes (ou des aires) bleues.

On remarque que la courbe verte est quasiment confondue avec la courbe bleue au lancement de Teen Quotes. Ceci s'explique par le fait qu'il était difficile de lancer Teen Quotes sans un contenu initial et une base d'utilisateurs quasi vide. Ainsi, il était habituel que je soumette et "m'auto-approuve" des quotes afin de proposer du contenu aux premiers visiteurs.

Le nombre de quotes approuvées suit une croissance quasi linéaire depuis la création du site. En effet, le nombre de quotes postées par jour est quasiment constant à 5.

En revanche, on remarque qu'à partir du mois de novembre 2012, le nombre de quotes refusées augmente énormément. Ceci s'explique par une hausse du nombre de soumissions de quotes (engendrée par une hausse du nombre de créations de comptes, mais nous le verrons plus loin !). Ce fort afflux de quotes a engendré beaucoup de refus car il n'était pas possible de publier toutes les quotes soumises. En conséquence, la modération des quotes soumises est très stricte depuis cette période car le nombre de quotes proposé est beaucoup plus important qu'auparavant.

3.2 Vous allez vite en besogne

Un jour, j'ai eu une super idée : j'ai voulu savoir combien de temps après leur inscription les utilisateurs qui ont soumis des quotes ont soumis leur première quote. Il faut savoir que 40 % des utilisateurs possédant un compte sur Teen Quotes ont déjà soumis au moins une quote. Il semblerait donc qu'une motivation importante pour créer un compte soit celle de pouvoir soumettre une quote. Vérifions ceci !




FIGURE 3.4 – Nombre de jours entre l'inscription et la première soumission d'une citation.

Pour obtenir les données nécessaires à la construction de ce graphique, voici l'idée suivie par l'algorithme :

1. On détermine tous les comptes ayant soumis au moins une quote. Pour chaque compte trouvé, on enregistre sa date d'inscription à Teen Quotes.
2. Pour chaque compte trouvé précédemment, on détermine la première citation soumise.
3. On calcule le nombre de jours entre la soumission de la première quote et la date de création du compte.

4. On enregistre dans une grande matrice le nombre de jours entre l'inscription et la première soumission de quote et le nombre de comptes ayant ce nombre de jours.
5. On élimine les lignes où il y a moins de 5 comptes qui ont soumis des citations au bout d'un nombre X de jours (que l'on note comme points aberrants).

Interprétons ceci maintenant :

- Constant sans appel : une écrasante majorité des utilisateurs ayant soumis des citations le font pour la première fois moins de 24 heures après avoir créé leur compte sur Teen Quotes. Notre hypothèse se confirme : la création du compte est bien souvent motivée par l'envie de soumettre une citation.
- Au delà de 5 jours d'écarts entre l'inscription et la soumission de la première quote, on retrouve très peu de comptes : à chaque fois moins de 20 comptes sont concernés.

Le détail des données est disponible sur <http://statistics.teen-quotes.com>. Il est intéressant de regarder les valeurs précises car il est difficile de se rendre compte de l'importance des cas hors épure sur le graphique présenté ci-dessus.

3.3 Petits floodeurs ou gros floodeurs ?

On rappelle la définition d'un *floodeur* d'après Wikipédia.

Flood est un anglicisme désignant une inondation, illustrant ainsi le flux de données ininterrompu et excessif transitant sur le réseau, provoquant alors des dégâts. Il a donné un verbe, *flooder*, et la personne qui *floode* est un *floodeur*.




FIGURE 3.5 – Nombre de citations soumises par les utilisateurs ayant soumis au moins une citation.

Le processus pour obtenir les données nécessaires à l'obtention de ce graphique est très similaire au processus précédent.

1. On détermine tous les comptes ayant soumis au moins une quote. Pour chaque compte trouvé, on enregistre sa date d'inscription à Teen Quotes.

2. Pour chaque compte trouvé précédemment, on compte le nombre de citations soumises.
3. On enregistre dans une grande matrice le nombre de citations soumises et le nombre de comptes ayant ce nombre de citations.

J'ai choisi de ne pas éliminer les points aberrants ici pour se rendre compte de la différence énorme entre l'épure des données et les points limites. Une fois de plus, le détail des données est disponible sur <http://statistics.teen-quotes.com>. Il est intéressant de regarder les valeurs précises car il est difficile de se rendre compte de l'importance des cas hors épure sur le graphique présenté ci-dessus. Interprétons ceci maintenant :

- Une écrasante majorité des gens ayant soumis des citations en soumettent moins de 5.
- Au delà de 10 citations soumises, on retrouve très peu de comptes : à chaque fois moins de 20 comptes sont concernés. La valeur maximale (493 citations soumises!) est attribuée à mon compte. Ceci s'explique par le fait que j'ai beaucoup contribué à remplir la base de données au lancement du site pour avoir un premier contenu sur Teen Quotes.

4 Les utilisateurs sont nos amis

Intéressons-nous maintenant au coeur de ce qui compose Teen Quotes : ~~du code!~~ les comptes d'utilisateurs.

4.1 Plus on est de fous, plus on rit

Dans un premier temps observons l'évolution du nombre de comptes créés sur Teen Quotes au cours du temps. Pour faire ceci, l'algorithme suivi est le suivant :

1. On définit une variable correspond au 1er jour du mois de la création de Teen Quotes.
2. On incrémente cette variable symbolisant le temps d'un mois, et on compte dans la table des comptes de Teen Quotes combien de comptes ont été créés avec une date d'inscription inférieure à celle-ci.
3. On répète le processus jusqu'au premier du mois courant en enregistrant dans une matrice à chaque étape la date à laquelle on s'intéresse et le nombre de comptes s'étant inscrits avant cette date.




FIGURE 4.1 – Création de comptes utilisateurs en fonction du temps.

Sur ce graphique on a représenté la période de développement entre novembre 2010 et mai 2011. Sans surprise le nombre d'inscriptions pour cette période est quasiment nul et correspond à quelques "privilégiés" qui ont eu accès à Teen Quotes avant le lancement en mai 2011.

De mai 2011 à novembre 2012 on observe une croissance quasi linéaire pour la création de comptes.

De novembre 2012 jusqu'à juin 2013 on observe une croissance se rapprochant d'une exponentielle, ralentie vers les derniers mois. Cette croissance fulgurante coïncide à la sortie de l'application iPhone / iTouch.

Tentons d'appliquer une régression pour se rapprocher de cette courbe. De toute évidence, il est inutile de tenter de modéliser la totalité de la courbe par modèle linéaire. Tentons une régression exponentielle de la forme e^{ax+b} .




FIGURE 4.2 – Création de comptes utilisateurs en fonction du temps.

Comme on ne peut pas faire une régression avec comme abscisse des dates au format (MM/AA), on va transformer l'abscisse en indiquant le nombre de mois depuis la création de Teen Quotes. La meilleure régression exponentielle est donnée par :

$$y = e^{0,249x+2,093}$$

Soit des coefficients :

$$\hat{a} = 0,249$$

$$\hat{b} = 2,093$$